

# Analyse du Comportement des Consommateurs

## Rapport Scientifique

Doaae Benmaalla

## 1 Introduction

L'évolution du commerce électronique et des stratégies marketing a rendu essentielle l'analyse du comportement des consommateurs. Le dataset *Consumer Behavior and Shopping Habits* disponible sur Kaggle constitue une base exploitable pour comprendre les habitudes d'achat, les facteurs influençant la satisfaction et les décisions d'achat, ainsi que les variables socio-économiques déterminantes.

### Problématique

Comment prédire efficacement les comportements d'achat et identifier les facteurs influençant la satisfaction ou la probabilité d'achat ?

### Objectifs

- Nettoyer et préparer un dataset brut orienté comportement consommateur.
- Explorer les relations entre les variables démographiques et les habitudes d'achat.
- Construire des modèles prédictifs performants.
- Évaluer les performances à l'aide de métriques adaptées : Accuracy, F1-Score, ROC-AUC, RMSE.
- Analyser les erreurs à travers la matrice de confusion.

## 2 Méthodologie

### 2.1 Nettoyage des données

Plusieurs opérations ont été réalisées :

- **Traitement des valeurs manquantes** : suppression ou imputation selon l'importance de la variable.
- **Encodage des variables catégorielles** : utilisation de One-Hot Encoding pour les variables non ordinales.

- **Standardisation** : normalisation des variables continues pour stabiliser les modèles basés sur la distance.

## 2.2 Choix des modèles

**Régression Logistique** Utilisée pour prédire des variables binaires (exemple : intention d'achat). Simple, interprétable et efficace sur des données structurées.

**Random Forest** Modèle non linéaire adapté pour capter les interactions complexes entre variables.

**Régression Linéaire / Random Forest Regressor** Utilisées pour prédire des variables continues comme les dépenses moyennes.

Ces choix reposent sur :

- la présence de variables mixtes (numériques + catégorielles),
- la taille modérée du dataset,
- le besoin de comparer modèles linéaires vs non linéaires.

## 3 Résultats et Discussion

Les principales métriques utilisées sont :

- **Accuracy** : proportion de prédictions correctes.
- **F1-Score** : utile pour les classes déséquilibrées.
- **ROC-AUC** : capacité du modèle à distinguer classes positives et négatives.
- **RMSE** : erreur moyenne pour les modèles de régression.

### 3.1 Exemple de résultats (indicatifs)

| Modèle                   | Accuracy | F1-Score | ROC-AUC | RMSE |
|--------------------------|----------|----------|---------|------|
| Régression Logistique    | 0.78     | 0.75     | 0.82    | –    |
| Random Forest Classifier | 0.85     | 0.84     | 0.90    | –    |
| Régression Linéaire      | –        | –        | –       | 12.4 |
| Random Forest Regressor  | –        | –        | –       | 9.8  |

Table 1: Performances des modèles

## 3.2 Analyse des erreurs : Matrice de Confusion

La matrice de confusion montre :

- Les vrais positifs : prédictions correctes de clients acheteurs.
- Les faux positifs : surestimation de l'intention d'achat.
- Les faux négatifs : cas critiques où des acheteurs sont mal classés.

Les modèles d'arbre (Random Forest) réduisent significativement les faux négatifs.

## 3.3 Interprétation

Les variables les plus importantes identifiées :

- Revenu mensuel.
- Fréquence d'achat.
- Satisfaction globale.
- Sensibilité aux promotions.

Ces informations permettent d'optimiser les stratégies marketing ciblées.

## 4 Conclusion

L'analyse du dataset montre que le comportement des consommateurs peut être prédit avec une précision satisfaisante, en particulier grâce aux modèles d'arbres comme Random Forest.

### Limites

- Dataset limité en taille.
- Peu de variables psychologiques ou comportementales fines.
- Présence éventuelle de biais démographiques.

### Pistes d'amélioration

- Ajouter des données textuelles (reviews, commentaires).
- Tester des modèles plus avancés : XGBoost, LightGBM.
- Collecter davantage de données pour réduire le surapprentissage.